

IA PARA DEVS

O CHAT GPT: COMO EXTRAIR O MÁXIMO DA FERRAMENTA NO
SEU DIA A DIA

AULA 02

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON.....	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?.....	11
REFERÊNCIAS.....	12

EMSE

O QUE VEM POR AÍ?

Nesta aula, vamos explorar o conceito de boas práticas em inteligência artificial (IA), especificamente no contexto de grandes modelos de linguagem (LLMs). Os LLMs (ou Large Language Model) são modelos poderosos que podem processar e gerar texto, e estão sendo usados em uma ampla gama de aplicações. Eles podem ser usados para tarefas como tradução, resumo e até mesmo geração de código.

No entanto, os LLMs também têm as suas limitações. Eles podem ser difíceis de entender, podem ser tendenciosos ou até mesmo prejudiciais. É importante estar ciente dessas limitações e tomar medidas para mitigá-las.

Nesta aula, vamos discutir as melhores práticas para usar os LLMs de forma responsável e ética., e também vamos explorar os desafios associados ao uso de LLMs e discutir possíveis soluções.

Objetivos de aprendizado

- Entender os conceitos de boas práticas e responsabilidade em IA.
- Aprender os benefícios e limitações dos LLMs.
- Aprender as melhores práticas para usar LLMs de forma responsável e ética.
- Explorar os desafios associados ao uso de LLMs e discutir possíveis soluções para esses desafios.

Pré-requisitos

- Conhecimento básico em IA e aprendizado de máquina.
- Experiência com Python e bibliotecas de aprendizado de máquina.

HANDS ON

Nesta aula, vamos explorar os grandes modelos de linguagem (LLMs), destacando seus pontos fortes e limitações. Vamos nos aprofundar na técnica de "Chain of Thought" ("Cadeia de Pensamento"), uma abordagem eficaz para melhorar o desempenho dos LLMs em tarefas complexas e que exigem raciocínio lógico.



SAIBA MAIS

Os modelos de linguagem grandes, conhecidos como LLMs (Large Language Models), têm revolucionado o campo do processamento de linguagem natural e aberto novas possibilidades em diversas áreas. Esses modelos poderosos, treinados em quantidades massivas de dados, são capazes de gerar texto, responder perguntas, traduzir idiomas e realizar uma variedade de tarefas relacionadas à linguagem com impressionante qualidade. No entanto, junto com seu enorme potencial, os LLMs também apresentam desafios e riscos que precisam ser considerados e abordados.




Figura 1 – Prompts – LLMs
Fonte: elaborado pelo autor (2024)

Boas práticas para o uso de LLMs

Entenda as limitações dos LLMs

Embora os LLMs sejam modelos poderosos, é crucial reconhecer que eles não são perfeitos. Eles podem apresentar dificuldades na compreensão do contexto, gerar respostas tendenciosas ou até mesmo produzir conteúdo prejudicial. É essencial estar ciente dessas limitações ao utilizar LLMs e tomar medidas para mitigá-las.

Uma das principais limitações dos LLMs é a sua dependência dos dados de treinamento. Se os dados utilizados para treinar o modelo contiverem vieses ou informações incorretas, esses problemas podem ser refletidos nas saídas geradas pelo modelo. Portanto, é importante ter cautela ao interpretar e utilizar os resultados produzidos pelos LLMs.

Além disso, os LLMs podem ter dificuldades em lidar com perguntas ou tarefas que exigem conhecimento especializado ou raciocínio complexo. Eles tendem a gerar respostas plausíveis com base nos padrões aprendidos, mas nem sempre são capazes de fornecer informações precisas ou aprofundadas sobre tópicos específicos.

Use os LLMs de forma responsável e ética

O uso responsável e ético dos LLMs é fundamental para aproveitar seus benefícios e minimizar possíveis danos. É importante estar ciente das implicações éticas associadas ao uso desses modelos e adotar práticas que promovam a equidade, a transparência e a segurança.

Ao utilizar LLMs, é essencial evitar seu uso para fins maliciosos ou prejudiciais, como a geração de desinformação, discurso de ódio ou conteúdo discriminatório. Os desenvolvedores e usuários de LLMs têm a responsabilidade de garantir que esses modelos sejam utilizados de maneira benéfica e alinhada com princípios éticos.

Além disso, é crucial considerar as questões de privacidade ao lidar com dados pessoais ou sensíveis. Os LLMs podem ser treinados em grandes conjuntos de dados que podem conter informações privadas. Portanto, é necessário adotar medidas de proteção de dados e garantir que o uso dos LLMs esteja em conformidade com as regulamentações de privacidade aplicáveis.

Monitore o uso dos LLMs

O monitoramento contínuo do uso dos LLMs é essencial para identificar e mitigar possíveis riscos. É importante estabelecer mecanismos de supervisão e controle para detectar usos inadequados ou resultados problemáticos gerados pelos modelos.

Isso pode envolver a implementação de sistemas de monitoramento automatizados que analisam as saídas dos LLMs em busca de conteúdo inapropriado, como linguagem ofensiva, informações falsas ou violações de direitos autorais. Além disso, a revisão humana pode ser necessária para avaliar a qualidade e a adequação das respostas geradas pelos modelos em contextos sensíveis.

O monitoramento também deve incluir a coleta de feedback dos usuários e a análise de casos de uso reais. Isso permite identificar problemas, ajustar os modelos e aprimorar continuamente o desempenho e a segurança dos LLMs.

Seja transparente sobre o uso dos LLMs

A transparência é um princípio fundamental no uso responsável dos LLMs. Os usuários têm o direito de saber quando estão interagindo com um modelo de IA e entender as limitações e riscos associados a essa interação.

É importante comunicar claramente aos usuários que eles estão se comunicando com um sistema baseado em LLM e não com um ser humano. Isso evita confusão e estabelece expectativas realistas sobre as capacidades e limitações do modelo.

Além disso, a transparência envolve fornecer informações sobre como os LLMs foram treinados, quais dados foram utilizados e quais medidas foram adotadas para mitigar possíveis vieses e riscos. Essa transparência ajuda a construir confiança e permite que os usuários tomem decisões informadas ao interagir com os LLMs.

Desafios Associados ao Uso de LLMs

Preconceito

Um dos principais desafios associados aos LLMs é o risco de perpetuar preconceitos existentes nos dados de treinamento. Como os LLMs aprendem com grandes quantidades de dados gerados por humanos, eles podem absorver e reproduzir vieses sociais, culturais e demográficos presentes nesses dados.

Esses preconceitos podem levar a resultados tendenciosos ou discriminatórios, reforçando estereótipos e perpetuando desigualdades. Por exemplo, um LLM treinado em dados com vieses de gênero pode gerar respostas que refletem esses vieses, atribuindo características ou papéis estereotipados a homens e mulheres.

Para mitigar esse problema, é necessário adotar técnicas de aprendizado de máquina justas e imparciais. Isso envolve a seleção cuidadosa dos dados de treinamento, a identificação e remoção de vieses nos dados e o uso de métricas de equidade para avaliar o desempenho dos modelos.

Interpretabilidade

Outro desafio associado aos LLMs é a dificuldade em interpretar e entender como eles chegam a suas respostas. Devido à sua complexidade e ao grande número de parâmetros, os LLMs são frequentemente considerados "caixas-pretas", o que significa que é difícil rastrear o raciocínio por trás de suas saídas.

Essa falta de interpretabilidade pode levantar preocupações sobre a confiabilidade e a transparência dos LLMs. Em contextos sensíveis, como medicina ou justiça, é crucial entender como o modelo chegou a uma determinada conclusão para garantir a responsabilidade e a tomada de decisões informadas.

Para melhorar a interpretabilidade dos LLMs, pesquisadores estão explorando técnicas como a explicação de modelos, que visa fornecer insights sobre os fatores que influenciam as previsões dos modelos. Além disso, o desenvolvimento de interfaces de usuário intuitivas e a criação de ferramentas de visualização podem ajudar a tornar os resultados dos LLMs mais compreensíveis e transparentes.

Segurança

A segurança é uma preocupação significativa no uso dos LLMs. Esses modelos poderosos podem ser explorados para fins maliciosos, como a geração de desinformação, a criação de conteúdo prejudicial ou até mesmo o desenvolvimento de malware.

Além disso, os LLMs podem ser vulneráveis a ataques adversários, nos quais dados manipulados são inseridos intencionalmente durante o treinamento ou a inferência para induzir comportamentos indesejados. Esses ataques podem comprometer a integridade e a confiabilidade dos modelos.

Para enfrentar esses desafios de segurança, é necessário adotar medidas robustas de proteção. Isso inclui a implementação de técnicas de detecção de anomalias para identificar e filtrar conteúdo malicioso, bem como o uso de criptografia e controles de acesso para proteger os modelos e os dados de treinamento.

Além disso, a educação dos usuários sobre os riscos potenciais e as melhores práticas de segurança é essencial para promover o uso responsável e seguro dos LLMs.

Possíveis Soluções para os Desafios

Mitigação de preconceito

Para mitigar o preconceito nos LLMs, várias abordagens podem ser adotadas. Uma delas é a seleção cuidadosa e a curadoria dos dados de treinamento, garantindo que sejam diversos, representativos e livres de vieses significativos. Isso pode envolver a coleta de dados de fontes variadas, a aplicação de técnicas de amostragem estratificada e a remoção de conteúdo tendencioso.

Além disso, técnicas de aprendizado de máquina justas e imparciais podem ser aplicadas durante o treinamento dos modelos. Isso inclui o uso de métricas de equidade para avaliar e ajustar o desempenho dos modelos em relação a diferentes grupos demográficos, bem como a incorporação de restrições de equidade nos algoritmos de treinamento.

Outra abordagem é a realização de auditorias regulares nos LLMs para identificar e corrigir possíveis vieses. Isso pode envolver a análise das saídas dos modelos em busca de padrões tendenciosos e a comparação do desempenho em diferentes subgrupos populacionais.

Interpretabilidade aprimorada

Para melhorar a interpretabilidade dos LLMs, várias técnicas podem ser empregadas. Uma delas é o uso de métodos de explicação de modelos, que visam fornecer insights sobre os fatores que influenciam as previsões dos modelos. Isso pode envolver a análise de importância de recursos, a visualização de ativações de neurônios ou a geração de explicações textuais.

Além disso, o desenvolvimento de interfaces de usuário intuitivas e ferramentas de visualização pode ajudar a tornar os resultados dos LLMs mais compreensíveis e transparentes. Isso pode incluir a criação de painéis interativos que permitem aos usuários explorar e entender as saídas dos modelos de maneira mais acessível.

Outra abordagem é o treinamento de modelos especializados em tarefas específicas, em vez de modelos genéricos. Modelos especializados tendem a ser mais interpretáveis, pois são treinados em domínios restritos e têm um escopo mais limitado de conhecimento.

Segurança aprimorada

Para melhorar a segurança dos LLMs, várias medidas podem ser adotadas. Uma delas é a implementação de técnicas de detecção de anomalias para identificar e filtrar conteúdo malicioso gerado pelos modelos. Isso pode envolver o uso de algoritmos de aprendizado de máquina para detectar padrões suspeitos nas saídas dos LLMs e sinalizar possíveis ameaças.

O QUE VOCÊ VIU NESTA AULA?

Os modelos de linguagem grandes (LLMs) têm o potencial de revolucionar a forma como interagimos com a tecnologia, e abrirão novas possibilidades em diversas áreas. No entanto, é crucial reconhecer e abordar os desafios associados ao seu uso, como preconceito, interpretabilidade e segurança. Ao adotar boas práticas, como entender as limitações dos LLMs, usá-los de forma responsável e ética, monitorar seu uso e ser transparente, podemos aproveitar seus benefícios e minimizar os riscos.

O campo dos LLMs está em constante evolução, e a pesquisa contínua é essencial para enfrentar os desafios existentes e desenvolver soluções inovadoras. A mitigação de preconceitos por meio de técnicas de aprendizado de máquina justas e imparciais, o aprimoramento da interpretabilidade por meio de métodos de explicação de modelos e interfaces de usuário intuitivas, e a melhoria da segurança por meio de técnicas de detecção de anomalias e medidas de proteção robustas são áreas promissoras de investigação. Ao abordar esses desafios de forma proativa e colaborativa, poderemos moldar um futuro em que os LLMs sejam ferramentas confiáveis e benéficas para a sociedade como um todo.

REFERÊNCIAS

- CHEN, M. et al. **Evaluating large language models trained on code.** arXiv:2107.03374. Cornell University, 2021. Disponível em: <https://arxiv.org/abs/2107.03374>. Acesso em: 03 mar. 2024.
- CHOWDHURY, A. et al. **PaLM: Scaling language modeling with pathways.** arXiv:2204.02311. Cornell University, 2022. Disponível em: <https://arxiv.org/abs/2204.02311>. Acesso em: 03 mar. 2024.
- HOFFMANN, J. et al. **Training compute-optimal large language models.** arXiv:2203.15556. Cornell University, 2022. Disponível em: <https://arxiv.org/abs/2204.02311>. Acesso em 03 mar. 2024.
- KOJIMA, T. et al. **Large language models are zero-shot reasoners.** arXiv:2205.11916. Cornell University, 2022. Disponível em: <https://arxiv.org/abs/2205.11916>. Acesso em: 03 mar. 2024.
- RAE, J. W. et al. **Scaling language models: Methods, analysis & insights from training gopher.** arXiv:2112.11446, 2021. Cornell University. Disponível em: <https://arxiv.org/abs/2112.11446>. Acesso em: 03 mar. 2024.
- TAY, Y. et al. **UI2: Unifying language learning paradigms.** 2022. arXiv:2205.05131, 2022. Cornell University. Disponível em: <https://arxiv.org/abs/2205.05131>. Acesso em: 03 mar. 2024.
- WANG, X. et al. **Self-consistency improves chain of thought reasoning in language models.** arXiv:2203.11171, 2022b. Disponível em: <https://arxiv.org/abs/2203.11171>. Acesso em: 03 mar. 2024.
- XUEZHI W. et. Al. **Self-consistency improves chain of thought reasoning in language models.** arXiv:2203.11171, 2022a. Disponível em: <https://arxiv.org/abs/2203.11171>. Acesso em: 03 mar. 2024.
- ZHAO, Z. et al. **Calibrate before use: Improving few-shot performance of language models.** arXiv:2102.09690, 2021. Disponível em: <https://arxiv.org/abs/2102.09690>. Acesso em: 03 mar. 2024.
- ZHOU, D. et al. **Least-to-most prompting enables complex reasoning in large language models.** arXiv:2205.10625, 2022. Disponível em: <https://arxiv.org/abs/2205.10625>. Acesso em: 03 mar. 2024.

PALAVRAS-CHAVE

Grandes Modelos de Linguagem (LLMs). Interpretabilidade. Chains of Thought. Inteligência Artificial.

EMENDAS



POSTECH