

ENRICO FIORI FERRAZ

POSTECH

IA PARA DEVS

FINE-TUNING E RAG PARA DOCUMENTOS

AULA 02

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
O QUE VOCÊ VIU NESTA AULA?	11
REFERÊNCIAS	12

EMSE

O QUE VEM POR AÍ?

Vamos entender o que é fine-tuning de LLMs, o que são foundation models e vamos executar o treinamento com base nos dados preparados na aula anterior. Entenderemos como configurar o modelo Llama 2, de 7 bilhões de parâmetros, e conceitos-chaves como tokenização de texto, quantização, transformers e adaptadores LoRA.

Após essa aula, você terá uma base sólida para conseguir realizar fine-tuning em diferentes modelos, uma vez que os conceitos passados aqui serão úteis para outros tipos de LLMs que você venha a usar futuramente.

HANDS ON

Vamos considerar que você é um engenheiro de inteligência artificial em um grande conglomerado de notícias e os acessos ao site vêm caindo cada vez mais ao longo dos anos com o crescimento das redes sociais. Cada vez mais, vê-se a tendência das plataformas “batalhando” entre si pelo tempo e atenção dos usuários. Portanto, analisando o tempo médio de leitura dos artigos do site, você conclui que eles extrapolam o tempo médio da sessão de usuário.

Para não impactar a qualidade dos artigos ou alterar processos internos que fogem da sua alçada, você decide criar uma inteligência artificial que resuma os textos integrais. Esse resumo permitirá ao usuário absorver os principais pontos e, se despertar o interesse, o encaminhará para a matéria completa.

Apesar do caso ser hipotético, as possibilidades que os LLMs proporcionam são reais e já impactam múltiplos setores da economia.

Nesta aula, vamos realizar o fine-tuning em um modelo de linguagem open source para resumir matérias de jornal, compreendendo os conceitos gerais para que você seja capaz de aplicar nos problemas que enfrenta no seu dia a dia.

SAIBA MAIS

É normal que tenham surgido dúvidas após assistir os vídeos, como o que é o Llama, porque utilizamos um modelo pré-treinado em nosso código ou até mesmo como é possível tornar um modelo genérico especialista em determinada tarefa. Aqui vamos nos aprofundar em cada um dos temas relevantes, para que, depois da leitura, você tenha uma base fundamentada sobre esses assuntos e consiga desenvolver seus próprios projetos daqui para a frente!

Foundational Models

Os foundational models são modelos de inteligência artificial treinados em vastos conjuntos de dados, que podem ser adaptados para uma ampla gama de tarefas sem a necessidade de treinamento do zero. Esses modelos são considerados fundacionais, pois servem como base para diversas aplicações, incluindo processamento de linguagem natural, visão computacional e outros domínios de IA.

Podemos pensar em modelos de IA como pessoas. Um modelo sem pré-treino é como uma criança, ou seja, é um quadro branco, pronto para absorver e compreender conhecimento. Já o foundational model é um adolescente, já possui a base geral sobre conhecimentos diversos, mas apesar de ser altamente adaptável, não é especialista em nada. Por fim, após o fine-tuning, o modelo se torna um “bacharel”, pois foi treinado para habilidades específicas, dependendo do domínio dos dados utilizado para esse aperfeiçoamento.




Figura 1 - Ilustração do papel dos Foundation Models
Fonte: [NVIDIA](#) (2023)

Características de um foundational model

- São pré-treinados com enormes quantidades de dados e podem exigir recursos computacionais significativos.
- São capazes de entender e gerar respostas para uma ampla variedade de perguntas e tarefas.
- Podem ser treinados (fine-tuned) para tarefas específicas com uma fração dos dados originalmente usados para treiná-los.

Principais Foundational Models

GPT-3

O GPT-3, desenvolvido pela OpenAI, é um modelo de linguagem com 175 bilhões de parâmetros, conhecido por sua habilidade em gerar textos coerentes e

contextuais com alta qualidade. Suas aplicações vão desde geração de conteúdo e tradução automática até assistente de código, sendo um dos modelos de IA mais versáteis e avançados disponíveis, capaz de realizar diversas tarefas sem necessidade de treinamento específico.

BERT

O BERT (Bidirectional Encoder Representations from Transformers), criado pelo Google, revolucionou o processamento de linguagem natural com sua abordagem de treinamento bidirecional, permitindo ao modelo entender o contexto de palavras com base em seu uso antes e depois no texto. Muito utilizado em tarefas de compreensão de texto, análise de sentimento e classificação, o BERT serve como base para muitos outros modelos na área de NLP.

T5

O modelo T5 (Text-to-Text Transfer Transformer), também do Google, aborda todas as tarefas de processamento de linguagem natural convertendo-as em problemas de conversão de texto para texto. Essa abordagem unificada permite que o T5 realize tarefas de tradução, sumarização, classificação e mais, apenas reformulando-as como problemas de geração de texto, aumentando sua flexibilidade e eficiência.

LLaMA

O LLaMA, da Meta AI, é um modelo de linguagem projetado para eficiência e adaptabilidade, capaz de executar tarefas complexas de processamento de linguagem natural, como tradução, resposta a perguntas e sumarização. Com diversas versões disponíveis para diferentes necessidades computacionais, o LLaMA oferece uma solução acessível para a implantação de tecnologias de linguagem avançadas em uma variedade de plataformas.

Por ser open source e um dos mais utilizados para tarefas que envolvem o processamento de linguagem natural, optamos por usar este modelo em nossa aula.

Fine-tuning

Fine-tuning ou “ajuste fino”, em tradução livre, é um método da área de aprendizado de máquina, especialmente no contexto de modelos fundacionais, como

os LLMs. É o processo de continuar o treinamento de um modelo pré-treinado sobre um novo conjunto de dados com uma tarefa específica em mente. Isso é feito para ajustar os parâmetros do modelo para que ele se torne mais especializado na tarefa desejada, sem perder as capacidades gerais aprendidas durante o treinamento inicial.

Hiperparâmetros

O fine-tuning envolve ajustar os hiperparâmetros do modelo, como a taxa de aprendizado. Quanto mais alto for o valor desse parâmetro, mais o modelo estará limitado aos dados de aprendizado, então é importante prestar atenção para que o modelo não perca a capacidade de generalizar para novos inputs, tamanho do dataset e número de epochs de treinamento.

A importância do fine-tuning está em permitir que um modelo complexo, treinado uma vez em um grande conjunto de dados, seja adaptado de forma eficiente para várias tarefas específicas. Isso não apenas economiza recursos, como também torna os modelos de aprendizado de máquina acessíveis para usos onde não se dispõe de grandes quantidades de dados ou capacidade computacional para treinar um modelo do zero.

Essa técnica é uma pedra angular para aplicações práticas de modelos de IA, permitindo que eles sejam customizados para necessidades específicas sem comprometer a base de conhecimento ampla que possuem.

Embedding

Embedding refere-se a uma função do modelo que retorna um vetor de representação densa para palavras ou frases em um espaço de características contínuo. Nas tarefas de PLN, embeddings são usados para capturar o significado semântico das palavras, de modo que palavras com significados semelhantes tenham embeddings próximos uns dos outros. Essas funções são fundamentais para muitos modelos de linguagem, pois permitem que o modelo processe texto de maneira eficaz, convertendo palavras em uma forma que pode ser manipulada matematicamente.

Tokenização

Tokenização é o processo de dividir o texto em peças menores, chamadas tokens, que podem ser palavras, subpalavras ou caracteres. Este é um passo fundamental antes de qualquer processamento em modelos de linguagem, pois transforma texto plano em uma forma que o modelo pode entender. No script utilizado na aula, a tokenização é usada para preparar os dados de entrada para o modelo de linguagem, garantindo que o texto seja dividido de maneira a maximizar a eficácia do treinamento e da geração de texto.

Quantização

Quantização é uma técnica para reduzir a precisão dos números usados para representar os pesos de um modelo de rede neural. Isso é feito para reduzir os requisitos de memória e acelerar o processamento, permitindo que os modelos sejam executados mais eficientemente em hardware com recursos limitados, como dispositivos móveis. Em nosso código, utilizamos a quantização de 4 bits, indicando que os pesos do modelo são representados com apenas 4 bits, o que é significativamente menor que a precisão típica de 32 bits usada em modelos de ponto flutuante. Dessa forma, conseguimos treinar o modelo sem necessitar de um hardware avançado, o que pode ser demasiadamente caro e inacessível.

Transformers

Arquitetura de modelo desenvolvida pela Google que revolucionou o campo do processamento de linguagem natural. Eles se baseiam em mecanismos de atenção, que permitem ao modelo ponderar a importância de diferentes palavras no texto, independentemente de sua posição. Esta arquitetura é altamente eficiente para tarefas que requerem compreensão do contexto em longas sequências de texto.

PEFT (Parameter Efficient Fine-Tuning)

É uma abordagem para ajustar modelos pré-treinados de uma maneira que seja computacionalmente eficiente. Isso geralmente envolve alterar apenas uma pequena fração dos pesos do modelo durante o fine-tuning, em vez de ajustar todo o modelo.

Essa técnica reduz a carga computacional e o uso de memória durante o treinamento, tornando o fine-tuning mais acessível e prático em uma variedade de situações.

LoRA (Low-Rank Adaptation)

LoRA é uma técnica específica dentro do espectro de métodos PEFT. Ela modifica apenas as camadas lineares do modelo, inserindo transformações de baixo posto que são treinadas enquanto os outros pesos são mantidos congelados. Isso permite que o modelo seja adaptado para tarefas específicas com apenas um pequeno acréscimo nos parâmetros, mantendo a maioria do conhecimento pré-treinado intacto e reduzindo a quantidade de dados necessários para efetuar o ajuste.




Figura 2 - Funcionamento dos adaptadores LoRA
Fonte: mercity.ai (2023)

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, pudemos aprofundar a parte teórica sobre as tecnologias que utilizamos em nosso código realizando um fine-tuning de um modelo fundacional Llama 2, onde conseguimos resumir notícias e verificar o output. Mas é importante salientar que o ecossistema de IA está evoluindo constantemente e as bibliotecas são atualizadas frequentemente. Tenha atenção para alterações, de modo que seus projetos continuem funcionando.

Estamos quase chegando ao fim da disciplina e na próxima vamos criar uma aplicação de IA implementando a técnica do RAG, Retrieval Augmented Generation, que nos permite fornecer respostas mais precisas e completas, pois vinculamos o conteúdo da resposta a uma fonte específica.

A gente se vê lá!

REFERÊNCIAS

CHURCH, K. W.; CHEN, Z.; MA, Y. **Emerging trends: A gentle introduction to fine-tuning. Natural Language Engineering.** 27(6), p. 763–778, 2021. Cambridge University Press.

KOLIDES, A. et al. **Artificial intelligence foundation and pre-trained models: Fundamentals, applications, opportunities, and social impacts. Simulation Modelling Practice and Theory.** 2023. Disponível em: <<https://www.sciencedirect.com/science/article/abs/pii/S1569190X2300031X?via%3Dihub>>. Acesso em: 27 de maio de 2024.

TOUVRON, H. et al. **LLaMA: Open and Efficient Foundation Language Models.** 2023. Disponível em < <https://arxiv.org/abs/2302.13971>> Acesso em: 27 de maio de 2024.

VASWANI, A. et al. **Attention Is All You Need.** Disponível em: <<https://arxiv.org/abs/1706.03762>>. Acesso em: 27 de maio de 2024.

PALAVRAS-CHAVE

Foundation Models. Fine-tuning. Llama.

EMEND



POSTECH